

本节内容

Cache

基本原理
基本概念

王道考研/CSKAOYAN.COM

1

存储系统存在的问题

双端口RAM、多模块存储器提高存储器的工作速度

优化后速度与CPU差距依然很大

更高速的存储单元设计

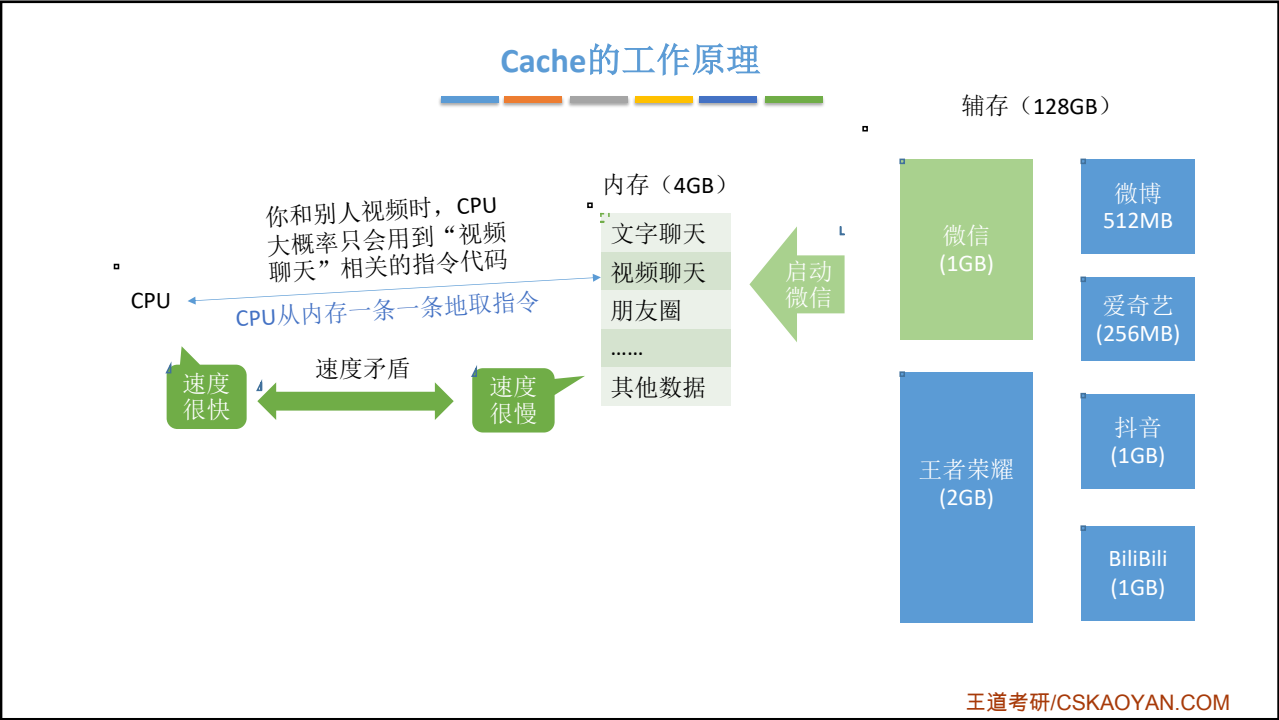
存储器价格↑ 容量↓

存储体系的改善
“Cache-主存”层次

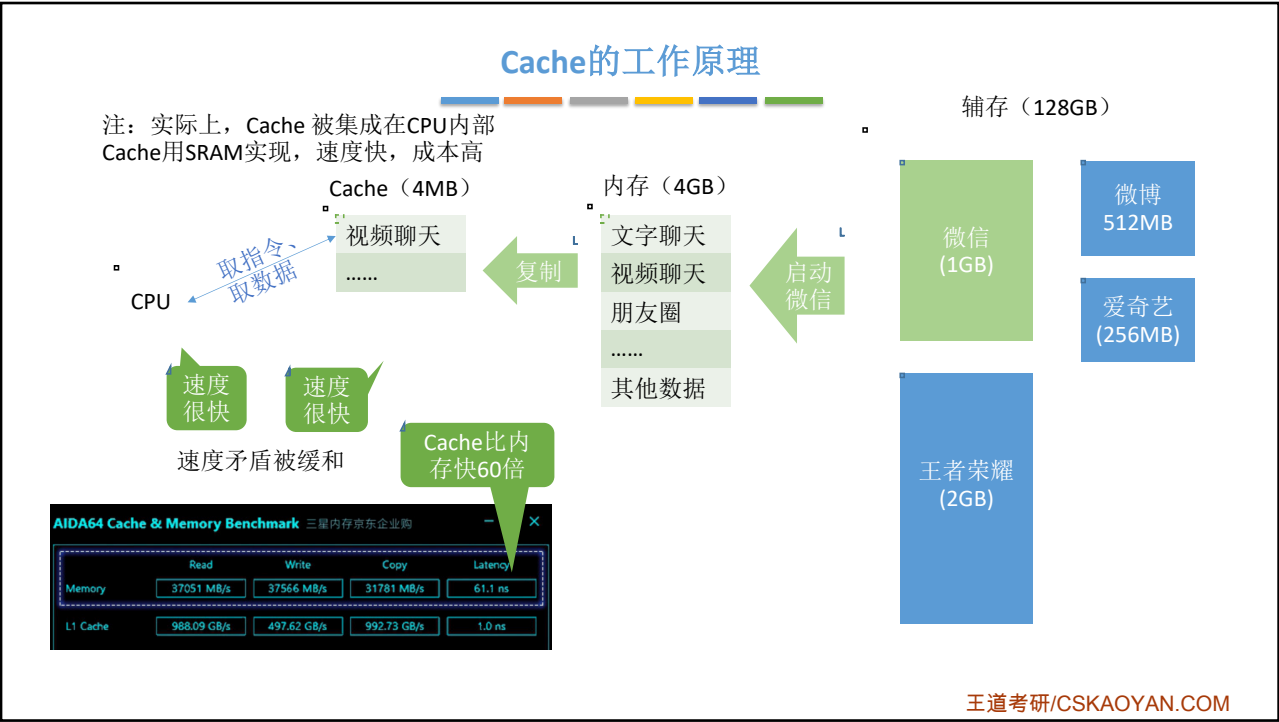
程序访问的局部性原理

王道考研/CSKAOYAN.COM

2



3



4

公众号：考研拼课
配套课程请关注

局部性原理

程序A:

```
1 int sumarrayrows(int a[M][N])
2 {
3     int i, j, sum = 0;
4     for (i = 0; i < M; i++)
5         for (j = 0; j < N; j++)
6             sum += a[i][j];
7     return sum;
8 }
```

程序B:

```
1 int sumarraycols(int a[M][N])
2 {
3     int i, j, sum = 0;
4     for (j = 0; j < N; j++)
5         for (i = 0; i < M; i++)
6             sum += a[i][j];
7     return sum;
8 }
```

0x0FC	I0	指令
0x100	I1	
0x104	⋮	
0x108	for内/外循环	
0x10C	⋮	
0x110	⋮	
0x114	I36	
⋮	⋮	
0x400	a[0][0]	数据
0x404	a[0][1]	
0x408	⋮	
0x40C	a[0][2047]	
0x410	a[1][0]	
0x414	a[1][1]	
⋮	⋮	
0x7A4		

←A

←V

指令和数据在内存中的存储

Eg: 数组元素、顺序执行的指令代码

空间局部性: 在最近的未来要用到的信息(指令和数据), 很可能与现在正在使用的信息在存储空间上是邻近的

时间局部性: 在最近的未来要用到的信息, 很可能是现在正在使用的信息

Eg: 循环结构的指令代码

基于局部性原理, 不难想到, 可以把CPU目前访问的地址“周围”的部分数据放到Cache中

程序B按“列优先”访问二维数组, 空间局部性更差

王道考研/CSKAOYAN.COM

5

性能分析

CPU

Cache (4MB)

- 视频聊天
- 朋友圈

访问耗时 t_c

内存 (4GB)

- 文字聊天
- 视频聊天
- 朋友圈
-
- 其他数据

访问耗时 t_m

设 t_c 为访问一次Cache所需时间, t_m 为访问一次主存所需时间

命中率H: CPU欲访问的信息已在Cache中的比率

缺失(未命中)率 $M = 1 - H$

Cache—主存系统的平均访问时间 t 为

$$t = Ht_c + (1 - H)(t_c + t_m)$$

先访问Cache, 若Cache未命中再访问主存

或 $t = Ht_c + (1 - H)t_m$

同时访问Cache和主存, 若Cache命中则立即停止访问主存

王道考研/CSKAOYAN.COM

6

性能分析

【例3-2】 假设Cache的速度是主存的5倍，且Cache的命中率为95%，则采用Cache后，存储器性能提高多少（设Cache和主存同时被访问，若Cache命中则中断访问主存）？

设Cache的存取周期为 t ，则主存的存取周期为 $5t$

若Cache和主存同时访问，命中时访问时间为 t ，未命中时访问时间为 $5t$
平均访问时间为 $0.95 \times t + 0.05 \times 5t = 1.2t$

故性能为原来的 $\frac{5t}{1.2t} \approx 4.17$ 倍

若先访问Cache再访问主存，命中时访问时间为 t ，未命中时访问时间为 $t+5t$
平均访问时间为 $T_a = 0.95 \times t + 0.05 \times 6t = 1.25t$

故性能为原来的 $\frac{5t}{1.25t} = 4$ 倍


王道考研/CSKAOYAN.COM

7

有待解决的问题

基于局部性原理，不难想到，可以把CPU目前访问的地址“周围”的部分数据放到Cache中。如何界定“周围”？

将主存的存储空间“分块”，如：每 1KB 为一块。主存与Cache之间以“块”为单位进行数据交换



王道考研/CSKAOYAN.COM

8

公众号：考研拼课
配套课程请关注

有待解决的问题

基于局部性原理，不难想到，可以把CPU目前访问的地址“周围”的部分数据放到Cache中。如何界定“周围”？

将主存的存储空间“分块”，如：每1KB为一块。主存与Cache之间以“块”为单位进行数据交换

注：操作系统中，通常将主存中的“一个块”也称为“一个页/页面/页框”

Cache中的“块”也称为“行”

Cache块号

0	1KB
1	1KB
2	1KB
...	...
6	1KB
7	1KB

Cache (8KB)

主存块号

0	1KB
1	1KB
2	1KB
3	1KB
...
4093	1KB
4094	1KB
4095	1KB

主存 (4MB)

主存的地址共22位：

块号	块内地址
12位	10位

$4M=2^{22}$, $1K=2^{10}$
整个主存被分为 $2^{12} = 4096$ 块

王道考研/CSKAOYAN.COM

9

有待解决的问题

Cache块号

0	1KB
1	1KB
2	1KB
...	...
6	1KB
7	1KB

Cache (8KB)

主存块号

0	1KB
1	1KB
2	1KB
3	1KB
...
4093	1KB
4094	1KB
4095	1KB

主存 (4MB)

注意：每次被访问的主存块，一定会被立即调入Cache

主存的地址共22位：

块号	块内地址
12位	10位

$4M=2^{22}$, $1K=2^{10}$
整个主存被分为 $2^{12} = 4096$ 块

- 如何区分 Cache 与 主存 的数据块对应关系？
- Cache 很小，主存很大。如果Cache满了怎么办？
- CPU修改了Cache中的数据副本，如何确保主存中数据母本的一致性？

——Cache和主存的映射方式

——替换算法

——Cache写策略

王道考研/CSKAOYAN.COM

10

